



**Jakub Bratko - Makaran**

---

***Wielowymiarowa analiza danych***

---

Rzeszów 2026

---

**Wydział Matematyki i Fizyki Stosowanej**

---



WYDZIAŁ  
MATEMATYKI  
I FIZYKI STOSOWANEJ  
POLITECHNIKI RZESZOWSKIEJ

## Spis treści

|      |                                                       |    |
|------|-------------------------------------------------------|----|
| 1.   | Informacje o projekcie i środowisku .....             | 3  |
| 2.   | Cel projektu.....                                     | 3  |
| 3.   | Opis danych źródłowych.....                           | 3  |
| 4.   | Proces ETL w SSIS.....                                | 4  |
| 4.1. | Package1_Staging.dtsx.....                            | 4  |
| 4.2. | Package3_Genres.dtsx .....                            | 5  |
| 4.3. | Package4_Countries_FuzzyLookup.dtsx .....             | 6  |
| 4.4. | Package5_FactMovies.dtsx .....                        | 7  |
| 4.5. | Package6_KPI.dtsx .....                               | 8  |
| 5.   | Model hurtowni danych .....                           | 8  |
| 6.   | Scenariusze / KPI .....                               | 9  |
| 7.   | Kostka OLAP i model wielowymiarowy .....              | 12 |
| 8.   | Data Mining .....                                     | 15 |
| 8.1. | Microsoft Clustering .....                            | 16 |
| 8.2. | Microsoft Decision Trees .....                        | 18 |
| 8.3. | Microsoft Linear Regression .....                     | 20 |
| 8.4. | Microsoft Naive Bayes.....                            | 22 |
| 9.   | Raport Power BI.....                                  | 24 |
| 9.1. | Dashboard filmów IMDb .....                           | 24 |
| 9.2. | Analiza finansowa filmów w latach 1980–2025 .....     | 25 |
| 9.3. | Analiza filmów według gatunków i krajów .....         | 26 |
| 9.4. | Trend, prognoza i dekompozycja danych filmowych ..... | 27 |
| 10.  | Podsumowanie / wnioski .....                          | 28 |

## *1. Informacje o projekcie i środowisku*

Projekt został wykonany w ramach przedmiotu Wielowymiarowa analiza danych. Tematem projektu była hurtownia danych i analiza wielowymiarowa danych o filmach. Do realizacji wykorzystano bazę danych imdb oraz dane źródłowe zaimportowane do tabeli staging\_movies.

Projekt został zrealizowany w środowisku Microsoft SQL Server. Do przygotowania procesów ETL wykorzystano SQL Server Integration Services, do budowy modelu wielowymiarowego i analiz Data Mining wykorzystano SQL Server Analysis Services Multidimensional and Data Mining Project, natomiast część raportowa została przygotowana w Power BI.

W projekcie wykorzystano serwer: *DESKTOP-IFD8LT5\WAD* oraz następujące narzędzia:

- SQL Server Management Studio,
- Visual Studio / SSDT,
- SSIS,
- SSAS Multidimensional,
- Data Mining,
- Power BI.


## *2. Cel projektu*

Celem projektu było przygotowanie hurtowni danych oraz przeprowadzenie wielowymiarowej analizy danych o filmach na podstawie zbioru zaimportowanego do bazy imdb. Projekt obejmował pełny proces analityczny: import danych źródłowych do tabeli stagingowej, oczyszczenie i transformację danych w SSIS, budowę modelu hurtowni danych, przygotowanie tabel KPI, utworzenie kostki OLAP w SSAS, wykonanie analiz Data Mining oraz przygotowanie raportu w Power BI. Dzięki temu możliwa była analiza filmów pod względem liczby produkcji, czasu wydania, gatunków, krajów produkcji, języków, przychodów, zysków, popularności oraz ocen użytkowników.

## *3. Opis danych źródłowych*

W projekcie wykorzystano zbiór danych zawierający informacje o filmach. Dane zostały zaimportowane do bazy imdb do tabeli stagingowej staging\_movies. Tabela zawiera m.in. identyfikator filmu, tytuł, datę premiery, budżet, przychód, ocenę, liczbę głosów, popularność, czas trwania, język oryginalny, gatunki, kraje produkcji oraz status filmu.

Liczba wszystkich rekordów w tabeli staging\_movies. wynosiła 1 087 995, natomiast liczba unikalnych filmów po kolumnie id wynosiła 1 087 812. Oznacza to, że w danych występowały duplikaty. Z tego powodu w dalszym procesie ETL zastosowano deduplikację danych, aby do wymiaru filmu oraz tabeli faktów trafiły wyłącznie unikalne filmy.



Rys.3.1 Struktura tabeli `staging_movies` oraz liczba rekordów w danych źródłowych.

Na rysunku 3.1 przedstawiono strukturę tabeli stagingowej oraz wynik zapytania sprawdzającego liczbę wszystkich rekordów i liczbę unikalnych filmów. Różnica między tymi wartościami wskazuje na występowanie duplikatów w danych źródłowych.

## 4. Proces ETL w SSIS


W projekcie przygotowano procesy ETL w środowisku SQL Server Integration Services. Ich zadaniem było zaimportowanie danych źródłowych, oczyszczenie ich, wykonanie deduplikacji oraz załadowanie danych do tabel wymiarów, tabel bridge, tabeli faktów oraz tabel KPI. Łącznie przygotowano pięć paczek ETL, co spełnia wymaganie wykonania co najmniej czterech przepływów ETL.

### 4.1. *Package1\_Staging.dtsx*


Pierwsza paczka ETL odpowiadała za przygotowanie danych źródłowych oraz załadowanie podstawowych wymiarów hurtowni danych. W ramach paczki wykonano czyszczenie tabeli `staging_movies`, import danych z pliku CSV do tabeli stagingowej, czyszczenie wymiarów podstawowych oraz ładowanie tabel `dim_date`, `dim_language`, `dim_status` i `dim_movie`.

Import danych został wykonany w przepływie Data Flow. Dane zostały pobrane z pliku źródłowego przy użyciu komponentu Flat File Source, następnie przetworzone przez Derived Column oraz Data Conversion, a na końcu załadowane do bazy danych przez OLE DB Destination. W tym etapie do tabeli `staging_movies` zaimportowano 1 087 995 rekordów.

W dalszej części paczki przygotowano podstawowe wymiary hurtowni. Ze względu na występowanie duplikatów po identyfikatorze filmu, podczas ładowania `dim_movie` zastosowano deduplikację, aby do wymiaru filmu trafiły wyłącznie unikalne rekordy.



Rys. 4.1 Control Flow paczki Package1\_Staging.dtsx




Rys. 4.2 Data Flow importu danych CSV do tabeli staging\_movies.

## 4.2. Package3\_Genres.dtsx

Paczka Package3\_Genres.dtsx odpowiadała za normalizację gatunków filmowych. W danych źródłowych gatunki były zapisane w jednej kolumnie genres, w której jeden film mógł posiadać kilka wartości oddzielonych przecinkami.

Proces ETL składał się z trzech kroków. Najpierw wykonano czyszczenie wcześniejszych danych dotyczących gatunków. Następnie załadowano unikalne gatunki do tabeli wymiaru dim\_genre. W ostatnim kroku utworzono tabelę pośrednią bridge\_movie\_genre, która przechowuje powiązania między filmami a gatunkami.

Zastosowanie tabeli bridge było konieczne, ponieważ między filmami i gatunkami występuje relacja wiele-do-wielu. Jeden film może należeć do wielu gatunków, a jeden gatunek może występować przy wielu filmach. W wyniku działania paczki uzyskano 20 gatunków w tabeli dim\_genre oraz 1 464 256 powiązań w tabeli bridge\_movie\_genre.



Rys. 4.3 Control Flow paczki Package3\_Genres.dtsx odpowiedzialnej za normalizację gatunków filmowych


### 4.3. Package4\_Countries\_FuzzyLookup.dtsx

Paczka Package4\_Countries\_FuzzyLookup.dtsx odpowiadała za standaryzację krajów produkcji filmów. W danych źródłowych kraje były zapisane w kolumnie tekstowej i mogły zawierać wiele wartości dla jednego filmu. Dlatego konieczne było przygotowanie danych do późniejszego utworzenia powiązań film–kraj.


Proces składał się z trzech głównych etapów. Najpierw przygotowano dane krajów do operacji Lookup. Następnie wykonano dopasowanie nazw krajów do tabeli dim\_country. Rekordy poprawnie dopasowane trafiały do ścieżki Lookup Match Output, natomiast rekordy niedopasowane były przekazywane dalej do Fuzzy Lookup, który umożliwiał dopasowanie nazw podobnych lub zawierających literówki.

Do testu mechanizmu Fuzzy Lookup użyto pomocniczej tabeli country\_dirty\_test, zawierającej przykładowe błędne nazwy krajów. Dzięki temu nie modyfikowano głównej tabeli z krajami. Rekordy po dopasowaniu zostały wykorzystane do załadowania tabeli bridge\_movie\_country, która przechowuje relację wiele-do-wielu między filmami i krajami produkcji.

W wyniku procesu uzyskano 91 krajów w tabeli dim\_country oraz 7223 unikalne powiązania film–kraj w tabeli bridge\_movie\_country.



Rys. 4.4 Control Flow paczki Package4\_Countries\_FuzzyLookup.dtsx




Rys. 4.5 Data Flow procesu Lookup i Fuzzy Lookup krajów

#### 4.4. Package5\_FactMovies.dtsx

Paczka Package5\_FactMovies.dtsx odpowiadała za przygotowanie i załadowanie tabeli faktów fact\_movies. Proces składał się z dwóch głównych kroków: wyczyszczenia wcześniejszych danych z tabeli faktów oraz ponownego załadowania aktualnych danych filmowych.

Tabela fact\_movies została zasilona danymi z tabeli staging\_movies po połączeniu ich z odpowiednimi wymiarami: dim\_movie, dim\_date, dim\_language oraz dim\_status. W tabeli faktów zapisano główne miary wykorzystywane później w analizie, takie jak budżet, przychód, zysk, średnia ocena, liczba głosów oraz popularność filmu.

Podczas ładowania tabeli faktów zastosowano deduplikację danych po identyfikatorze filmu, aby każdy film został zapisany tylko raz. Po wykonaniu procesu tabela fact\_movies zawierała 1 087 812 rekordów.



Rys. 4.6 Control Flow paczki Package5\_FactMovies.dtsx

| SQLQuery1.sql - DE...D8LT5\Student (57))                |         |
|---------------------------------------------------------|---------|
| SELECT COUNT(*) AS liczba_rekordow<br>FROM fact_movies; |         |
| 100 %                                                   |         |
| Results Messages                                        |         |
| liczba_rekordow                                         | 1087812 |


Rys. 4.7 Liczba rekordów w tabeli faktów fact\_movies po zakończeniu procesu ETL



## 4.5. Package6\_KPI.dtsx

Paczka Package6\_KPI.dtsx odpowiadała za przygotowanie tabel KPI wykorzystywanych w dalszej analizie oraz w raportach Power BI. Proces rozpoczynał się od wyczyszczenia wcześniejszych tabel KPI, a następnie wykonywał cztery scenariusze analityczne jako zadania Execute SQL Task.

W ramach paczki przygotowano zestawienia dotyczące liczby filmów według roku, wyników finansowych według roku, filmów według gatunku oraz filmów według kraju produkcji. Dzięki temu dane zostały wcześniej zagregowane i mogły zostać wykorzystane w części raportowej projektu.



Rys. 4.8 Control Flow paczki Package6\_KPI.dtsx


## 5. Model hurtowni danych

Na potrzeby projektu przygotowano model hurtowni danych oparty na tabeli faktów oraz tabelach wymiarów. Centralnym elementem modelu jest tabela fact\_movies, która przechowuje główne miary wykorzystywane w analizie filmów, takie jak budżet, przychód, zysk, średnia ocena, liczba głosów oraz popularność.

Tabela faktów została połączona z wymiarami dim\_movie, dim\_date, dim\_language oraz dim\_status, co umożliwia analizę danych według filmu, daty wydania, języka oryginalnego i statusu filmu. Dodatkowo w modelu uwzględniono wymiary dim\_genre oraz dim\_country.

Ponieważ jeden film może należeć do wielu gatunków i jednocześnie być powiązany z wieloma krajami produkcji, zastosowano tabele pośrednie bridge\_movie\_genre oraz bridge\_movie\_country. Dzięki temu możliwe było poprawne odwzorowanie relacji wiele-do-wielu w modelu hurtowni danych.





Rys. 5.1 Model hurtowni danych dla analizy filmów

## 6. Scenariusze / KPI

Zgodnie z wymaganiami projektu przygotowano cztery scenariusze/KPI związane z analizą wielowymiarową danych filmowych. Wskaźniki zostały opracowane dwuetapowo. Najpierw w procesie ETL przygotowano pomocnicze tabele KPI, a następnie w kostce SSAS utworzono formalne wskaźniki KPI w zakładce KPIs.

W paczce Package6\_KPI.dtsx wykonano zadania Execute SQL Task, które odpowiadały za przygotowanie tabel analitycznych wykorzystywanych później w raportach i analizie danych. Paczka obejmowała czyszczenie tabel KPI oraz przygotowanie czterech zestawień: filmów według roku, finansów według roku, filmów według gatunku oraz filmów według kraju produkcji.

| Nazwa KPI                    | Cel analizy                               | Użyte miary                                                                   |
|------------------------------|-------------------------------------------|-------------------------------------------------------------------------------|
| <i>kpi_movies_by_year</i>    | Analiza liczby filmów według roku wydania | liczba filmów, średnia ocena, średnia popularność                             |
| <i>kpi_finance_by_year</i>   | Analiza finansowa filmów według roku      | suma budżetu, suma przychodów, suma zysku, średni zysk                        |
| <i>kpi_movies_by_genre</i>   | Analiza filmów według gatunku             | liczba filmów, średnia ocena, średnia popularność, liczba filmów z przychodem |
| <i>kpi_movies_by_country</i> | Analiza filmów według kraju produkcji     | liczba filmów, średnia ocena, średnia popularność, suma przychodów            |

| SELECT TOP 10 * FROM kpi_movies_by_genre; |               |                          |                  |                     |                    |  |
|-------------------------------------------|---------------|--------------------------|------------------|---------------------|--------------------|--|
| 100 %                                     |               |                          |                  |                     |                    |  |
| Results Messages                          |               |                          |                  |                     |                    |  |
| genre_name                                | liczba_filmow | liczba_ocenionych_filmow | srednia_ocena    | srednia_popularnosc | filmy_z_przychodem |  |
| 1 Music                                   | 51978         | 19403                    | 6,92975313095913 | 1,2377351956597     | 857                |  |
| 2 Western                                 | 8947          | 4522                     | 5,55970809376382 | 2,10405722588577    | 262                |  |
| 3 Science Fiction                         | 21384         | 12218                    | 5,77475855295466 | 3,80457351290685    | 1499               |  |
| 4 Adventure                               | 23959         | 14836                    | 6,14869236991103 | 4,74076547435202    | 2465               |  |
| 5 Drama                                   | 232152        | 110162                   | 6,00601840925183 | 1,99269874909542    | 8980               |  |
| 6 Animation                               | 60375         | 21571                    | 6,41514069815957 | 1,8808115942029     | 1196               |  |
| 7 History                                 | 17065         | 8594                     | 6,54154060972772 | 2,22033401699385    | 844                |  |
| 8 Family                                  | 28306         | 15658                    | 6,32839443096181 | 3,03705928071787    | 1683               |  |
| 9 Unknown                                 | 361094        | 56204                    | 6,23959148815031 | 0,824353215506212   | 683                |  |
| 10 Thriller                               | 45876         | 29161                    | 5,71403586982614 | 3,9133533873921     | 3797               |  |

| SELECT TOP 10 * FROM kpi_movies_by_country; |               |                          |                  |                     |                |  |
|---------------------------------------------|---------------|--------------------------|------------------|---------------------|----------------|--|
| 100 %                                       |               |                          |                  |                     |                |  |
| Results Messages                            |               |                          |                  |                     |                |  |
| country_name                                | liczba_filmow | liczba_ocenionych_filmow | srednia_ocena    | srednia_popularnosc | suma_przychodu |  |
| 1 Austria                                   | 80            | 73                       | 6,13698630136986 | 4,35                | 158210597      |  |
| 2 Luxembourg                                | 12            | 12                       | 5,66666666666667 | 10,6666666666667    | 16408989       |  |
| 3 United Kingdom                            | 636           | 625                      | 6,5184           | 16,1540880503145    | 35807582491    |  |
| 4 Spain                                     | 171           | 164                      | 6,23170731707317 | 10,233918128655     | 2737032900     |  |
| 5 Soviet Union                              | 21            | 21                       | 6,90476190476191 | 9,52380952380952    | 164366         |  |
| 6 New Zealand                               | 19            | 19                       | 6,84210526315789 | 28,3157894736842    | 4199079014     |  |
| 7 Russia                                    | 14            | 13                       | 5,61538461538462 | 7                   | 441097017      |  |
| 8 Peru                                      | 6             | 6                        | 6,5              | 21                  | 383943266      |  |
| 9 Slovakia                                  | 5             | 5                        | 6,6              | 12,4                | 172586404      |  |
| 10 Solomon Islands                          | 1             | 1                        | 7                | 19                  | 98126565       |  |

Rys. 6.1 Przykładowe wyniki tabel KPI przygotowanych w projekcie

Dodatkowo w kostce OLAP\_176774\_Movies utworzono formalne wskaźniki KPI, które pozwalają ocenić najważniejsze aspekty finansowe danych filmowych. Wskaźniki zostały zdefiniowane w zakładce KPIs projektu 176774\_OLAP\_Multi.

| Nazwa KPI                   | Cel analizy                                              |
|-----------------------------|----------------------------------------------------------|
| KPI_Przychody_vs_Budzet     | porównanie przychodów filmów względem budżetu            |
| KPI_Zysk_Filmow             | ocena zysku generowanego przez filmy                     |
| KPI_Rentownosc              | ocena relacji zysku do poniesionego budżetu              |
| KPI_Sredni_Przychod_Na_Film | analiza średniego przychodu przypadającego na jeden film |

Dla każdego KPI określono wartość analizowaną, wartość docelową, status oraz trend. Kolumna Value przedstawia aktualną wartość miary, Goal oznacza wartość docelową, Status informuje o poziomie realizacji celu, a Trend pokazuje kierunek zmian wskaźnika.

KPI Organizer

KPI\_Przychody\_vs\_Budzet

KPI\_Zysk\_Filmow

KPI\_Rentownosc

KPI\_Sredni\_Przychod\_Na\_Film

Calculation Tools

Metadata

Functions

Templates

Search Model

Measure Group:

<All>

OLAP\_176774\_Movies

Measures

Dim Date

Dim Language

Dim Movie

Dim Status

KPI

Name:

KPI\_Przychody\_vs\_Budzet

Associated measure group:

<All>

Value Expression

[Measures].[Revenue]

Goal Expression

[Measures].[Budget]

Status

Status indicator:

Gauge

Status expression:

CASE  
WHEN [Measures].[Revenue] >= [Measures].[Budget] THEN 1  
WHEN [Measures].[Revenue] >= [Measures].[Budget] \* 0.75 THEN 0  
ELSE -1  
END

Trend

Trend indicator:

Standard arrow

Trend expression:

CASE  
WHEN [Measures].[Profit] > 0 THEN 1  
WHEN [Measures].[Profit] = 0 THEN 0  
ELSE -1  
END

Rys.6.2 Definicja wskaźników KPI w kostce OLAP\_176774\_Movies


Poprawność działania KPI została sprawdzona w Browserze kostki OLAP w podziale na lata. Dzięki temu możliwa była ocena zmian przychodów, budżetu, zysku, rentowności oraz średniego przychodu na film w kolejnych latach.

| Dimension          | Hierarchy                     | Operator                     | Filter Expression              |
|--------------------|-------------------------------|------------------------------|--------------------------------|
| <Select dimension> |                               |                              |                                |
| Year               | KPI_Przychody_vs_Budzet Value | KPI_Przychody_vs_Budzet Goal | KPI_Przychody_vs_Budzet Status |
| 2008               | 24090874679                   | 10683216091                  | 1                              |
| 2009               | 31321262308                   | 10891564901                  | 1                              |
| 2010               | 25419393615                   | 11069429342                  | 1                              |
| 2011               | 28847766697                   | 11192380992                  | 1                              |
| 2012               | 29483350500                   | 10478296133                  | 1                              |
| 2013               | 30937192520                   | 11107943728                  | 1                              |
| 2014               | 31858914701                   | 10871528670                  | 1                              |
| 2015               | 31459079484                   | 10058892305                  | 1                              |
| 2016               | 34343404838                   | 12748273405                  | 1                              |
| 2017               | 35835075582                   | 10939504618                  | 1                              |
| 2018               | 33138323534                   | 10511445655                  | 1                              |
| 2019               | 32201914652                   | 10084396357                  | 1                              |
| 2020               | 10234201817                   | 5024939543                   | 1                              |
| 2021               | 20023516306                   | 9445317348                   | 1                              |
| 2022               | 25715491474                   | 10983352349                  | 1                              |
| 2023               | 27596976262                   | 11798993351                  | 1                              |
| 2024               | 15702805626                   | 5460937653                   | 1                              |
| 2025               | 8864968781                    | 3552937996                   | 1                              |

Rys. 6.3 Weryfikacja działania KPI w Browserze kostki w podziale na lata


## 7. Kostka OLAP i model wielowymiarowy

W projekcie utworzono model wielowymiarowy w środowisku SQL Server Analysis Services. Projekt otrzymał nazwę 176774\_OLAP\_Multi, a główna kostka została nazwana OLAP\_176774\_Movies.



Rys. 7.1 Struktura kostki OLAP\_176774\_Movies

Kostka została oparta na tabeli faktów **fact\_movies** oraz wymiarach Dim Movie, Dim Date, Dim Language i Dim Status. W kostce zdefiniowano miary wykorzystywane w dalszej analizie, takie jak Budget, Revenue, Profit, Vote Average, Vote Count, Popularity oraz Fact Movies Count.




Rys. 7.2 Powiązania wymiarów z grupą miar w kostce OLAP

W wymiarze daty utworzono hierarchię kalendarzową:


Year → Quarter → Month → Day → Full Date

Hierarchia ta umożliwia analizowanie danych filmowych na różnych poziomach szczegółowości czasu - od roku, przez kwartał i miesiąc, aż do konkretnej daty premiery filmu.



Rys. 7.3 Hierarchia daty utworzona w wymiarze Dim Date

W kostce dodano również miary obliczane, m.in. średni przychód na film oraz rentowność. Dzięki temu możliwa była analiza danych nie tylko na podstawie prostych sum, ale również na podstawie wskaźników finansowych.



Rys. 7.4 Miary obliczane utworzone w zakładce Calculations

Poprawność działania kostki sprawdzono w zakładce Browser, wykonując przykładowe analizy, m.in. liczbę filmów według roku, przychody i zysk według roku, oceny według języka oraz popularność filmów według statusu.

OLAP\_176774\_Movies

Metadata

Search Model

<All>

OLAP\_176774\_Movies

Measures

Fact Movies

Budget

Fact Movies Count

Popularity

Profit

Revenue

Vote Average

Vote Count

Rentowność

Średni przychód na film

| Dimension          |             |                   | Hierarchy               |
|--------------------|-------------|-------------------|-------------------------|
| <Select dimension> |             |                   |                         |
| Year               | Revenue     | Fact Movies Count | Średni przychód na film |
| 2010               | 25419393615 | 22075             | 1151501,40951302        |
| 2011               | 28847766697 | 23745             | 1214898,57641609        |
| 2012               | 29483350500 | 25865             | 1139893,69804755        |
| 2013               | 30937192520 | 28416             | 1088724,39893018        |
| 2014               | 31858914701 | 30332             | 1050340,06003561        |
| 2015               | 31459079484 | 32005             | 982942,64908608         |
| 2016               | 34343404838 | 33626             | 1021334,82537322        |
| 2017               | 35835075582 | 37391             | 958387,729186168        |
| 2018               | 33138323534 | 39809             | 832432,955713532        |
| 2019               | 32201914652 | 43820             | 734867,974714742        |
| 2020               | 10234201817 | 43145             | 237204,816711091        |
| 2021               | 20023516306 | 46620             | 429504,854268554        |
| 2022               | 25715491474 | 48485             | 530380,354212643        |
| 2023               | 27596976262 | 49971             | 552259,835944848        |
| 2024               | 15702805626 | 40371             | 388962,513338783        |
| 2025               | 8864968781  | 38332             | 231268,099264322        |

| Dimension          | Hierarchy         |
|--------------------|-------------------|
| <Select dimension> |                   |
|                    |                   |
| Status Name        | Fact Movies Count |
| Canceled           | 17                |
| In Production      | 13657             |
| Planned            | 1582              |
| Post Produc...     | 4698              |
| Released           | 1067819           |
| Rumored            | 39                |
|                    | Popularity        |
|                    | 11                |
|                    | 9186              |
|                    | 1087              |
|                    | 4342              |
|                    | 1552626           |
|                    | 26                |

| Dimension          | Hierarchy               |
|--------------------|-------------------------|
| <Select dimension> |                         |
|                    |                         |
| Year               | Revenue                 |
| 2010               | 25419393615             |
| 2011               | 28847766697             |
| 2012               | 29483350500             |
| 2013               | 30937192520             |
| 2014               | 31858914701             |
| 2015               | 31459079484             |
| 2016               | 34343404838             |
| 2017               | 35835075582             |
| 2018               | 33138323534             |
| 2019               | 32201914652             |
| 2020               | 10234201817             |
| 2021               | 20023516306             |
| 2022               | 25715491474             |
| 2023               | 27596976262             |
| 2024               | 15702805626             |
| 2025               | 8864968781              |
|                    | Fact Movies Count       |
|                    | 22075                   |
|                    | 23745                   |
|                    | 25865                   |
|                    | 28416                   |
|                    | 30332                   |
|                    | 32005                   |
|                    | 33626                   |
|                    | 37391                   |
|                    | 39809                   |
|                    | 43820                   |
|                    | 43145                   |
|                    | 46620                   |
|                    | 48485                   |
|                    | 49971                   |
|                    | 40371                   |
|                    | 38332                   |
|                    | Średni przychód na film |
|                    | 1151501,40951302        |
|                    | 1214898,57641609        |
|                    | 1139893,69804755        |
|                    | 1088724,39893018        |
|                    | 1050340,06003561        |
|                    | 982942,64908608         |
|                    | 1021334,82537322        |
|                    | 958387,729186168        |
|                    | 832432,955713532        |
|                    | 734867,974714742        |
|                    | 237204,816711091        |
|                    | 429504,854268554        |
|                    | 530380,354212643        |
|                    | 552259,835944848        |
|                    | 388962,513338783        |
|                    | 231268,099264322        |

Rys. 7.5 Przykładowe analizy danych w Browserze kostki OLAP.

## *8. Data Mining*

W projekcie wykonano cztery analizy Data Mining w środowisku SQL Server Analysis Services. Celem tego etapu było wykorzystanie algorytmów eksploracji danych do wykrywania zależności, grupowania filmów oraz klasyfikacji wybranych cech filmów na podstawie danych przygotowanych w hurtowni.


Wykonano następujące modele Data Mining:

- Microsoft Clustering,
- Microsoft Decision Trees,
- Microsoft Linear Regression,
- Microsoft Naive Bayes.




## 8.1. Microsoft Clustering

Pierwszym przygotowanym modelem był model Microsoft Clustering. Celem analizy było pogrupowanie filmów w klastry na podstawie podobieństwa ich cech liczbowych i opisowych.



Rys. 8.1 Wybór Microsoft Clustering


Do utworzenia modelu wykorzystano widok v\_mining\_movies\_clustering. W analizie użyto m.in. takich zmiennych jak: budget, revenue, profit, vote\_average, vote\_count, popularity, language\_code oraz year. Kluczem modelu była kolumna fact\_id.




Rys. 8.2 Zmienne treningowe

Model utworzył 10 klastrów filmów. Klastry różniły się między sobą m.in. poziomem budżetu, przychodu, zysku, popularności, liczby głosów oraz językiem filmu. Dzięki temu możliwe było wskazanie grup filmów o podobnych cechach finansowych i ocenowych.

Wyniki modelu zostały przedstawione w widokach Cluster Diagram, Cluster Profiles oraz Cluster Characteristics. Diagram klastrów pokazuje ogólny podział filmów na grupy, natomiast profile klastrów pozwalają porównać cechy poszczególnych grup.



Rys. 8.3 Cluster Diagram



Rys. 8.4 Cluster Profiles

## 8.2. Microsoft Decision Trees

Drugim przygotowanym modelem Data Mining był model Microsoft Decision Trees. Celem analizy była klasyfikacja filmów do jednej z trzech kategorii popularności: Niska, Średnia lub Wysoka.

SQLQuery2.sql - DE...D8LT5(Student (54))

```
SELECT TOP 50 *
FROM v_mining_movies_popularity_tree;

SELECT popularity_category, COUNT(*) AS liczba_filmow
FROM v_mining_movies_popularity_tree
GROUP BY popularity_category;
```

100 %

Results Messages

|    | fact_id | title                              | year | language_code | status_name | budget    | revenue   | profit    | vote_average | vote_count | popularity | popularity_category |
|----|---------|------------------------------------|------|---------------|-------------|-----------|-----------|-----------|--------------|------------|------------|---------------------|
| 37 | 37      | Walk the Line                      | 2005 | en            | Released    | 28000000  | 186797986 | 158797986 | 7            | 2629       | 18         | Wysoka              |
| 38 | 38      | Million Dollar Baby                | 2004 | en            | Released    | 30000000  | 216763646 | 186763646 | 8            | 8874       | 21         | Wysoka              |
| 39 | 39      | Billy Elliot                       | 2000 | en            | Released    | 5000000   | 109280263 | 104280263 | 8            | 3561       | 22         | Wysoka              |
| 40 | 40      | American History X                 | 1998 | en            | Released    | 20000000  | 23875127  | 3875127   | 8            | 10729      | 36         | Wysoka              |
| 41 | 41      | War of the Worlds                  | 2005 | en            | Released    | 132000000 | 603873119 | 471873119 | 6            | 7728       | 41         | Wysoka              |
| 42 | 42      | Mars Attacks!                      | 1996 | en            | Released    | 70000000  | 101371017 | 31371017  | 6            | 5008       | 23         | Wysoka              |
| 43 | 43      | Before Sunrise                     | 1995 | en            | Released    | 2500000   | 5987386   | 3487386   | 8            | 3722       | 22         | Wysoka              |
| 44 | 44      | Memento                            | 2000 | en            | Released    | 9000000   | 39723096  | 30723096  | 8            | 13723      | 32         | Wysoka              |
| 45 | 45      | Blade Runner                       | 1982 | en            | Released    | 28000000  | 41722424  | 13722424  | 8            | 12770      | 57         | Wysoka              |
| 46 | 46      | Hero                               | 2002 | zh            | Released    | 31000000  | 177394432 | 146394432 | 8            | 2032       | 21         | Wysoka              |
| 47 | 47      | Before Sunset                      | 2004 | en            | Released    | 2700000   | 15992615  | 13292615  | 8            | 3074       | 20         | Wysoka              |
| 48 | 48      | Nausicaä of the Valley of the Wind | 1984 | ja            | Released    | 1000000   | 3301446   | 2301446   | 8            | 3174       | 37         | Wysoka              |
| 49 | 49      | Miami Vice                         | 2006 | en            | Released    | 135000000 | 163794509 | 28794509  | 6            | 1599       | 18         | Wysoka              |
| 50 | 50      | Open Water                         | 2003 | en            | Released    | 130000    | 54667954  | 54537954  | 6            | 981        | 13         | Wysoka              |

|   | popularity_category | liczba_filmow |
|---|---------------------|---------------|
| 1 | Średnia             | 889837        |
| 2 | Niska               | 160953        |
| 3 | Wysoka              | 16938         |

Rys. 8.5 Widok danych przygotowanych do modelu drzewa decyzyjnego

Do utworzenia modelu wykorzystano widok `v_mining_movies_popularity_tree`. Zmienną przewidywaną była kolumna `popularity_category`, natomiast jako zmienne wejściowe wykorzystano m.in. `budget`, `language_code`, `profit`, `revenue`, `vote_average`, `vote_count` oraz `year`. Kolumna `popularity` nie została użyta jako zmienna wejściowa, ponieważ na jej podstawie utworzono kategorię popularności. Dzięki temu model nie otrzymał bezpośrednio gotowej odpowiedzi.

Data Mining Wizard

**Specify the Training Data**  
Specify the columns used in your analysis.

Mining model structure:


| Tables/Columns                                                      | Key                                 | Input                               | Predict...                          |
|---------------------------------------------------------------------|-------------------------------------|-------------------------------------|-------------------------------------|
| <input checked="" type="checkbox"/> v_mining_movies_popularity_tree |                                     |                                     |                                     |
| <input checked="" type="checkbox"/> budget                          | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| <input checked="" type="checkbox"/> fact_id                         | <input checked="" type="checkbox"/> | <input type="checkbox"/>            | <input type="checkbox"/>            |
| <input checked="" type="checkbox"/> language_code                   | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| <input type="checkbox"/> popularity                                 | <input type="checkbox"/>            | <input type="checkbox"/>            | <input type="checkbox"/>            |
| <input checked="" type="checkbox"/> popularity_category             | <input type="checkbox"/>            | <input type="checkbox"/>            | <input checked="" type="checkbox"/> |
| <input checked="" type="checkbox"/> profit                          | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| <input checked="" type="checkbox"/> revenue                         | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| <input type="checkbox"/> status_name                                | <input type="checkbox"/>            | <input type="checkbox"/>            | <input type="checkbox"/>            |
| <input type="checkbox"/> title                                      | <input type="checkbox"/>            | <input type="checkbox"/>            | <input type="checkbox"/>            |
| <input checked="" type="checkbox"/> vote_average                    | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| <input checked="" type="checkbox"/> vote_count                      | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| <input checked="" type="checkbox"/> year                            | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |

Recommend inputs for currently selected predictable:

< Back Next > Finish >> Cancel


Rys. 8.6 Zmienne wejściowe i zmienna przewidywana w modelu Decision Trees

W danych przygotowanych do modelu najwięcej filmów należało do kategorii Srednia, następnie do kategorii Niska, a najmniej do kategorii Wysoka. Model drzewa decyzyjnego pozwolił wskazać, które cechy filmów wpływały na przypisanie ich do określonej kategorii popularności.



Rys. 8.7 Drzewo decyzyjne dla klasyfikacji kategorii popularności filmu


Wizualizacja drzewa pokazała podziały danych m.in. według średniej oceny filmu oraz roku wydania. Dodatkowo widok Dependency Network wskazał zależności pomiędzy kategorią popularności a takimi zmiennymi jak Vote Average, Vote Count, Year, Language Code oraz Profit.



Rys. 8.8 Sieć zależności dla modelu Microsoft Decision Trees

### 8.3. Microsoft Linear Regression

Trzecim przygotowanym modelem Data Mining był model Microsoft Linear Regression. Celem analizy była predykcja przychodu filmu na podstawie wybranych cech opisujących produkcję.



```
SELECT TOP 50 *
FROM v_mining_movies_revenue_regression;


SELECT COUNT(*) AS liczba_rekordow
FROM v_mining_movies_revenue_regression;
```

|   | fact_id | title              | year | runtime | budget   | revenue   | vote_average | vote_count | popularity |
|---|---------|--------------------|------|---------|----------|-----------|--------------|------------|------------|
| 1 | 3       | Four Rooms         | 1995 | 98      | 4000000  | 4257354   | 6            | 2436       | 15         |
| 2 | 4       | Judgment Night     | 1993 | 109     | 21000000 | 12136938  | 7            | 302        | 14         |
| 3 | 7       | Star Wars          | 1977 | 121     | 11000000 | 775398007 | 8            | 19155      | 89         |
| 4 | 8       | Finding Nemo       | 2003 | 100     | 94000000 | 940335536 | 8            | 18061      | 55         |
| 5 | 9       | Forrest Gump       | 1994 | 142     | 55000000 | 677387716 | 8            | 25409      | 93         |
| 6 | 10      | American Beauty    | 1999 | 122     | 15000000 | 356296601 | 8            | 11260      | 30         |
| 7 | 11      | Citizen Kane       | 1941 | 119     | 839727   | 23218000  | 8            | 5034       | 28         |
| 8 | 12      | Dancer in the Dark | 2000 | 141     | 12800000 | 40031879  | 8            | 1618       | 18         |

|   | liczba_rekordow |
|---|-----------------|
| 1 | 13621           |

Rys. 8.9 Widok danych przygotowanych do modelu regresji liniowej

Do utworzenia modelu wykorzystano widok v\_mining\_movies\_revenue\_regression. Dane zostały ograniczone do filmów posiadających dodatni budżet i dodatni przychód, dzięki czemu model był budowany na rekordach zawierających pełniejsze informacje finansowe. Widok zawierał 13 621 rekordów.



Data Mining Wizard

**Specify the Training Data**  
Specify the columns used in your analysis.

Mining model structure:


| Tables/Columns                     | Key                                 | Input                               | Predict...                          |
|------------------------------------|-------------------------------------|-------------------------------------|-------------------------------------|
| v_mining_movies_revenue_regression |                                     |                                     |                                     |
| budget                             | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| fact_id                            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            | <input type="checkbox"/>            |
| popularity                         | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| revenue                            | <input type="checkbox"/>            | <input type="checkbox"/>            | <input checked="" type="checkbox"/> |
| runtime                            | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| title                              | <input type="checkbox"/>            | <input type="checkbox"/>            | <input type="checkbox"/>            |
| vote_average                       | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| vote_count                         | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| year                               | <input type="checkbox"/>            | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |

Recommend inputs for currently selected predictable: Suggest

< Back Next > Finish >> Cancel


Rys. 8.10 Zmienne wejściowe i zmienna przewidywana w modelu Linear Regression

Zmienną przewidywaną była kolumna revenue, natomiast jako zmienne wejściowe wykorzystano m.in. budget, popularity, runtime, vote\_average, vote\_count oraz year. Kluczem modelu była kolumna fact\_id.



Rys. 8.11 Wynik modelu regresji liniowej dla predykcji przychodu filmu


Model regresji liniowej wskazał zależności między przychodem filmu a pozostałymi cechami. Największe znaczenie dla predykcji przychodu miały przede wszystkim budget, vote\_count oraz vote\_average, co zostało potwierdzone w widoku Dependency Network. Oznacza to, że przychód filmu był najsilniej powiązany z budżetem produkcji, liczbą głosów oraz oceną użytkowników.



Rys. 8.12 Sieć zależności dla modelu Microsoft Linear Regression

## 8.4. Microsoft Naive Bayes

Czwartym przygotowanym modelem Data Mining był model Microsoft Naive Bayes. Celem analizy była klasyfikacja filmów do jednej z trzech kategorii oceny: Niska, Srednia lub Wysoka.



```
SELECT rating_category, COUNT(*) AS liczba_filmow
FROM v_mining_movies_rating_bayes
GROUP BY rating_category;

SELECT TOP 50 *
FROM v_mining_movies_rating_bayes;
```


| rating_category | liczba_filmow |
|-----------------|---------------|
| Srednia         | 185702        |
| Niska           | 747366        |
| Wysoka          | 134660        |

| id | title                             | year | language_code | budget    | popularity | profit    | revenue | vote_count | vote_average | rating_category |
|----|-----------------------------------|------|---------------|-----------|------------|-----------|---------|------------|--------------|-----------------|
| 35 | Paradise Now                      | 2005 | en            | 2000000   | 3395627    | 1395627   | 7       | 232        | 9            | Wysoka          |
| 36 | Brazil                            | 1985 | en            | 15000000  | 9900000    | -5100000  | 8       | 3026       | 21           | Wysoka          |
| 37 | Walk the Line                     | 2005 | en            | 28000000  | 186797...  | 158797... | 7       | 2629       | 18           | Wysoka          |
| 38 | Million Dollar Baby               | 2004 | en            | 30000000  | 216763...  | 186763... | 8       | 8874       | 21           | Wysoka          |
| 39 | Billy Elliot                      | 2000 | en            | 5000000   | 109280...  | 104280... | 8       | 3561       | 22           | Wysoka          |
| 40 | American History X                | 1998 | en            | 20000000  | 23875127   | 3875127   | 8       | 10729      | 36           | Wysoka          |
| 41 | War of the Worlds                 | 2005 | en            | 132000... | 603873...  | 471873... | 6       | 7728       | 41           | Srednia         |
| 42 | Mars Attacks!                     | 1996 | en            | 70000000  | 101371...  | 313710... | 6       | 5008       | 23           | Srednia         |
| 43 | Before Sunrise                    | 1995 | en            | 2500000   | 5987386    | 3487386   | 8       | 3722       | 22           | Wysoka          |
| 44 | Memento                           | 2000 | en            | 9000000   | 39723096   | 307230... | 8       | 13723      | 32           | Wysoka          |
| 45 | Blade Runner                      | 1982 | en            | 28000000  | 41722424   | 137224... | 8       | 12770      | 57           | Wysoka          |
| 46 | Hero                              | 2002 | zh            | 31000000  | 177394...  | 146394... | 8       | 2032       | 21           | Wysoka          |
| 47 | Before Sunset                     | 2004 | en            | 2700000   | 15992615   | 132926... | 8       | 3074       | 20           | Wysoka          |
| 48 | Nausicaä of the Valley of the ... | 1984 | ja            | 1000000   | 3301446    | 2301446   | 8       | 3174       | 37           | Wysoka          |
| 49 | Miami Vice                        | 2006 | en            | 135000... | 163794...  | 287945... | 6       | 1599       | 18           | Srednia         |
| 50 | Open Water                        | 2003 | en            | 130000    | 54667954   | 545379... | 6       | 981        | 13           | Srednia         |

Rys. 8.13 Widok danych przygotowanych do modelu Naive Bayes

Do utworzenia modelu wykorzystano widok v\_mining\_movies\_rating\_bayes. Zmienną przewidywaną była kolumna rating\_category, natomiast jako zmienne wejściowe wykorzystano m.in. budget, language\_code, popularity, profit, revenue, vote\_count oraz year. Kolumna vote\_average nie została użyta jako zmienna wejściowa, ponieważ na jej podstawie utworzono kategorię oceny filmu.



Data Mining Wizard

**Specify the Training Data**  
Specify the columns used in your analysis.

Mining model structure:


| Tables/Columns               | Key                                 | Input                               | Predict...                          |
|------------------------------|-------------------------------------|-------------------------------------|-------------------------------------|
| v_mining_movies_rating_bayes |                                     |                                     |                                     |
| budget                       |                                     | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| fact_id                      | <input checked="" type="checkbox"/> | <input type="checkbox"/>            | <input type="checkbox"/>            |
| language_code                |                                     | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| popularity                   |                                     | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| profit                       |                                     | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| rating_category              |                                     | <input type="checkbox"/>            | <input checked="" type="checkbox"/> |
| revenue                      |                                     | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| title                        |                                     | <input type="checkbox"/>            | <input type="checkbox"/>            |
| vote_average                 |                                     | <input type="checkbox"/>            | <input type="checkbox"/>            |
| vote_count                   |                                     | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |
| year                         |                                     | <input checked="" type="checkbox"/> | <input type="checkbox"/>            |

Recommend inputs for currently selected predictable:

< Back Next > Finish >> Cancel


Rys. 8.14 Zmienne wejściowe i zmienna przewidywana w modelu Naive Bayes

W danych przygotowanych do modelu najwięcej filmów należało do kategorii Niska, następnie do kategorii Średnia, a najmniej do kategorii Wysoka. Model Naive Bayes pozwolił określić zależności pomiędzy kategorią oceny a pozostałymi cechami filmu.



Rys. 8.15 Sieć zależności dla modelu Microsoft Naive Bayes

W widoku Dependency Network przedstawiono zmienne powiązane z kategorią oceny, takie jak popularność, budżet, przychód, zysk, liczba głosów oraz rok wydania. Dodatkowo w widoku Attribute Profiles zaprezentowano rozkład wybranych cech dla poszczególnych kategorii ocen.



Rys. 8.16 Profile atrybutów dla modelu Microsoft Naive Bayes

Wykonane modele Data Mining pozwoliły przeanalizować dane filmowe z różnych perspektyw. Model klastrowania umożliwił podział filmów na grupy o podobnych cechach, drzewo decyzyjne pozwoliło klasyfikować popularność filmów, regresja liniowa została wykorzystana do predykcji przychodów, a model Naive Bayes do klasyfikacji kategorii ocen. Dzięki temu etap Data Mining uzupełnił analizę wielowymiarową o elementy eksploracji danych i predykcji.




## 9. Raport Power BI

Ostatnim etapem projektu było przygotowanie raportu w Power BI. Raport składa się z czterech stron, a każda z nich zawiera cztery wizualizacje. W analizie wykorzystano dane pochodzące z kostki OLAP oraz z tabel KPI przygotowanych w bazie imdb.

### 9.1. Dashboard filmów IMDb

Pierwsza strona raportu pełni funkcję dashboardu głównego. Zawiera podstawowe wskaźniki dotyczące zbioru filmów, takie jak liczba filmów, łączne przychody oraz łączny zysk. Dodatkowo przedstawiono liczbę wydanych filmów według roku, co pozwala ocenić zmiany liczby produkcji filmowych w czasie.

Źródłem danych dla tej strony była kostka OLAP\_176774\_Movies.




Rys. 9.1 Dashboard filmów IMDb

## 9.2. Analiza finansowa filmów w latach 1980–2025

Druga strona raportu przedstawia analizę finansową filmów w latach 1980–2025. Pokazano łączny budżet filmów według roku, porównanie przychodów i zysków, średni przychód przypadający na jeden film oraz wskaźnik rentowności.

W analizie wykorzystano miary finansowe z kostki OLAP, m.in. Budget, Revenue, Profit, Średni Przychód Na Film oraz Rentownosc. Rok 2026 został pominięty, ponieważ jest rokiem niepełnym i mógłby zaburzać interpretację trendów.




Rys. 9.2 Analiza finansowa filmów w latach 1980–2025

### 9.3. Analiza filmów według gatunków i krajów

Trzecia strona raportu przedstawia analizę filmów według krajów produkcji oraz gatunków. Wykorzystano tutaj tabele KPI przygotowane w bazie imdb.

Na stronie przedstawiono Top 10 krajów według liczby filmów, liczbę filmów według gatunku, średnią ocenę filmów według gatunku oraz Top 10 krajów według przychodów. Dzięki temu możliwa była analiza danych z perspektywy wymiarów opisowych.

Średnia ocena została liczona tylko dla filmów posiadających głosy, aby filmy bez ocen nie zaniżały wyniku.




Rys. 9.3 Analiza filmów według gatunków i krajów

## 9.4. Trend, prognoza i dekompozycja danych filmowych

Czwarta strona raportu zawiera elementy analizy zaawansowanej. Przygotowano prognozę liczby filmów według roku, trend przychodów oraz drzewa dekompozycji dla przychodów i zysku.

Do drzewa dekompozycji wykorzystano widok `v_pbi_decomposition_movies`, który umożliwił analizę danych według roku, gatunku, języka oraz kraju produkcji. W Power BI zastosowano także linię trendu oraz prognozę z obszarem niepewności.

Strona ta realizuje część analityczną obejmującą trend, prognozę oraz dekompozycję danych filmowych.



Rys. 9.4 Trend, prognoza i dekompozycja danych filmowych

## *10. Podsumowanie / wnioski*

W projekcie przygotowano pełny proces analizy wielowymiarowej danych o filmach. Dane źródłowe zostały zaimportowane do tabeli staging\_movies, a następnie oczyszczone i przetworzone w procesach ETL przygotowanych w SSIS. Na ich podstawie utworzono hurtownię danych opartą na tabeli faktów fact\_movies, wymiarach oraz tabelach pośrednich dla relacji wiele-do-wielu.

W dalszej części projektu przygotowano scenariusze KPI, kostkę OLAP w SQL Server Analysis Services oraz cztery modele Data Mining. Analizy umożliwiły badanie danych filmowych według czasu, gatunków, krajów produkcji, języków, przychodów, zysków, popularności oraz ocen. Kończącym etapem było przygotowanie raportu Power BI składającego się z czterech stron, obejmujących dashboard główny, analizę finansową, analizę według gatunków i krajów oraz trend, prognozę i dekompozycję danych. Projekt zrealizował pełną ścieżkę przetwarzania i analizy danych: od źródła danych, przez ETL i hurtownię danych, aż po OLAP, Data Mining oraz wizualizację wyników w Power BI.